

Projeto 1: Regressão com MLP e Estudo de Ablação

Introdução às Redes Neurais Artificiais | Aline Breda Kuster 168495

Repositório: github.com/aline-kuster/Redes-Neurais---P1

1. Objetivo e Configuração Experimental

O objetivo deste projeto é treinar uma MLP para uma tarefa de regressão (prever y a partir de x , num dataset de 300 pontos) e, a partir de um baseline bem definido, isolar o efeito de quatro técnicas de regularização/otimização (Dropout, L2, L1 e Momentum) sobre o erro de teste e sobre o overfitting, testando cada uma separadamente antes de avaliar se combiná-las traz ganho adicional.

1.1. Pré-processamento e Partição dos Dados

O dataset (300 pontos) foi dividido em treino (10%, 30 pontos), validação (10%, 30 pontos) e teste (80%, 240 pontos), com $\text{seed}=42$. A proporção reduzida de treino é intencional, para forçar overfitting e tornar visível o efeito de cada técnica de regularização. O atributo x foi padronizado (z-score) usando média/desvio calculados só no treino, aplicando o mesmo transform em validação e teste, para não vaziar nenhuma informação desses conjuntos para o pré-processamento.

1.2. Definição e Otimização Empírica do Baseline (Vanilla)

O baseline é uma MLP treinada só com SGD puro (sem momentum, sem L1/L2/Dropout). A configuração final foi definida por busca empírica: 6 arquiteturas $\times$ 3 taxas de aprendizado (18 combinações, 3000 épocas cada, todas partindo da mesma seed para permitir comparação justa), escolhida pelo menor MSE de validação atingido durante o treino. Ativação (ReLU) e tamanho de lote (8) ficaram fixos; não foi usado early stopping. A Tabela 1 resume o espaço de busca e a configuração final; a Tabela 1b traz o log completo das 18 combinações.

Hiperparâmetro	Valores Explorados	Configuração Escolhida
Topologia	(8,) (16,) (32,) (16,16) (32,16) (64,64)	Entrada→Densa(64)→Densa(64)→Saída(1)
Ativação	ReLU (fixa)	ReLU
Otimizador / η	SGD puro; $\eta \in \{0.1, 0.05, 0.01\}$	SGD ($\eta = 0.1$)
Lote / Custo	batch=8 (fixo); MSE	batch=8; MSELoss
Parada / Seed	nº fixo de épocas (sem early stop)	3000 épocas; seed=42

Tabela 1: Espaço de busca e configuração final do baseline.

A melhor configuração foi hidden=(64,64), $\eta=0.1$ (MSE de treino final 0.079; menor MSE de validação: 0.312), usada como base fixa em todas as ablações a seguir.

Arq.	η	Pesos	MSE tr.	MSE val.	MSE val. mín.
(8,)	0.1	25	0.358	0.794	0.628
(8,)	0.05	25	0.272	0.712	0.600
(8,)	0.01	25	0.241	0.638	0.625
(16,)	0.1	49	0.273	0.674	0.613
(16,)	0.05	49	0.266	0.635	0.594
(16,)	0.01	49	0.228	0.619	0.615
(32,)	0.1	97	0.260	0.783	0.582
(32,)	0.05	97	0.233	0.706	0.568
(32,)	0.01	97	0.241	0.602	0.589
(16,16)	0.1	321	0.128	0.465	0.417
(16,16)	0.05	321	0.137	0.530	0.465
(16,16)	0.01	321	0.216	0.580	0.572
(32,16)	0.1	609	0.161	0.523	0.452
(32,16)	0.05	609	0.139	0.534	0.478
(32,16)	0.01	609	0.209	0.636	0.582
(64,64)	0.1	4353	0.079	0.476	0.312
(64,64)	0.05	4353	0.073	0.462	0.327
(64,64)	0.01	4353	0.188	0.649	0.556

Tabela 1b: erro de treino e validação das 18 configurações avaliadas como baseline.

1.3. Escolha dos Hiperparâmetros de Cada Ablação (por Validação)

Para cada técnica de ablação, foi testada uma pequena grade de valores candidatos (3 valores por técnica), mantendo fixos a arquitetura, o η e a seed do baseline. A escolha do valor final seguiu o mesmo critério do baseline: o menor MSE de validação, nunca o resultado no conjunto de teste, para que o teste permaneça intocado até a avaliação final. A Tabela 1c mostra os candidatos testados e o valor escolhido (destacado) para cada técnica.

Técnica	Valor Testado	MSE de Validação
Dropout	$p = 0.1$	0.4190
Dropout	$p = 0.3$	0.4724
Dropout	$p = 0.5$	0.5344
L2	$\lambda = 1e-6$	0.3039
L2	$\lambda = 1e-5$	0.3110
L2	$\lambda = 1e-4$	0.3081
L1	$\lambda = 1e-7$	0.3058
L1	$\lambda = 1e-6$	0.3091
L1	$\lambda = 1e-5$	0.3104

Técnica	Valor Testado	MSE de Validação
Momentum	$\beta = 0.5$	0.4163
Momentum	$\beta = 0.7$	0.4042
Momentum	$\beta = 0.9$	0.7007

Tabela 1c: candidatos testados e valor escolhido de cada hiperparâmetro de ablação, por MSE de validação.

2. Dinâmica de Treinamento do Baseline




Fig. 1: Baseline, treino x validação (SGD puro)

Sem momentum, o SGD puro é instável: a validação do baseline (Fig. 1) apresenta picos de MSE de até 0.9, mesmo depois de 2000 épocas, reflexo do gradiente ruidoso de mini-lotes pequenos (batch=8, só 30 exemplos de treino) sem nenhuma suavização. O overfitting já aparece nas primeiras centenas de épocas: a curva de treino cai rapidamente até cerca de 0.08-0.1, enquanto a validação estabiliza numa faixa muito mais alta, entre 0.33 e 0.5. Essa distância grande e persistente entre as duas curvas é esperada com apenas 30 exemplos de treino para uma rede de 4353 parâmetros, e é exatamente o cenário que o estudo de ablação a seguir tenta atenuar.

3. Estudo de Ablação: Efeito de Cada Técnica

Mantendo arquitetura, seed e η do baseline fixos, cada variação a seguir altera um único hiperparâmetro por vez, já escolhido pela busca de validação da Tabela 1c. A avaliação final de cada configuração é feita uma única vez sobre o conjunto de teste (240 pontos, nunca usado no treino nem na escolha de hiperparâmetros). A Tabela 2 resume todos os resultados; os gráficos a seguir mostram, para cada técnica, a curva de treino e validação do baseline (tracejado) contra a curva da variação (sólido).

Modelo / Variação	MSE	RMSE	MAE	R ²
Baseline Vanilla	0.5229	0.7231	0.5644	-0.014
+ Dropout ($p=0.1$)	0.4197	0.6479	0.5155	0.186
+ L2 ($\lambda=1e-6$)	0.5142	0.7171	0.5621	0.003
+ L1 ($\lambda=1e-7$)	0.5334	0.7303	0.5780	-0.035
+ Momentum ($\beta=0.7$)	0.4479	0.6693	0.5356	0.131
Combinado (Dropout+Momentum)	0.4881	0.6986	0.5507	0.053

Tabela 2: Resultados no conjunto de teste. Treino de 3000 épocas fixas (sem early stopping) para todas as configurações.

3.1. Dropout, L2 e L1: as três formas de regularizar os pesos




Fig. 2: Dropout ($p=0.1$)




Fig. 3: L2 ($\lambda=1e-6$)




Fig. 4: L1 ($\lambda=1e-7$)

Fig. 2-4: baseline (tracejado) x cada variação (sólido), treino e validação.

O Dropout desliga aleatoriamente uma fração dos neurônios a cada passo de treino, o que impede a rede de se apoiar sempre nos mesmos neurônios para memorizar os 30 pontos de treino. Na Fig. 2, a curva de treino do Dropout (azul sólido) fica visivelmente acima da do baseline, confirmando essa dificuldade extra de decorar; a validação (vermelho sólido) fica um pouco acima da média do baseline, mas muito mais estável, sem os picos extremos que o baseline apresenta. Essa curva de validação, com só 30 pontos por época, é naturalmente ruidosa; a evidência mais confiável está na Tabela 2, avaliada uma única vez sobre os 240 pontos de teste: $R^2=0.186$, o melhor resultado de toda a tabela. Já L2 e L1 (Fig. 3 e 4) ficam com as curvas praticamente sobrepostas às do baseline: os valores de λ escolhidos pela busca de validação (Tabela 1c) são pequenos demais para mudar o comportamento da rede de forma visível. O L2 soma ao erro o quadrado de cada peso, encolhendo todos suavemente sem zerar nenhum, e trouxe uma melhora discreta ($R^2=0.003$). O L1 soma o valor absoluto de cada peso, o que tende a zerar pesos pequenos por completo; o baseline tinha 28/4353 pesos praticamente nulos, e com L1 esse número sobe para 48/4353, confirmando o efeito esperado de esparsidade, mesmo sem melhora no

erro ($R^2=-0.035$, levemente pior que o baseline). Em ambos os casos, valores maiores de λ pioravam ainda mais o MSE de validação (Tabela 1c), então mesmo o melhor λ disponível não foi suficiente para gerar um efeito forte.

3.2. Momentum e o Modelo Combinado




Fig. 5: Momentum ($\beta=0.7$)




Fig. 6: Combinado (Dropout+Momentum)

Fig. 5-6: baseline (tracejado) x cada variação (sólido), treino e validação.

O Momentum não é uma técnica de regularização, e sim de otimização: em vez de seguir só o gradiente do lote atual, ele acumula uma fração ($\beta=0.7$) da velocidade dos passos anteriores, suavizando a trajetória diante de gradientes ruidosos, típicos de mini-lotes pequenos. Na Fig. 5, a validação do Momentum se estabiliza de forma mais consistente depois de ~ 1000 épocas, com menos oscilação de curto prazo do que o baseline. Isso se traduziu no segundo melhor resultado isolado, $R^2=0.131$, atrás só do Dropout. Como Dropout e Momentum foram as duas técnicas isoladas com melhor R^2 , testou-se combiná-las (Fig. 6): a validação do combinado fica bem mais estável que a do baseline, um comportamento parecido com o do Momentum isolado, mas o resultado final no teste foi $R^2=0.053$, melhor que baseline/L1/L2, porém pior que Dropout (0.186) ou Momentum (0.131) isolados. Isso mostra que os dois mecanismos não são simplesmente aditivos: o ruído que o Dropout introduz ao desligar neurônios parece interferir com a suavização que o Momentum faz sobre a trajetória do gradiente. Esse é um dos achados centrais deste estudo: melhorar duas técnicas separadamente não garante que a combinação delas melhore mais ainda.

4. Avaliação Final do Melhor Modelo e Limitações




Fig. 7: Real x Previsto (teste) — baseline x Dropout




Fig. 8: Resíduos do melhor modelo (Dropout)

O parity plot (Fig. 7) compara, nos 240 pontos de teste, o baseline (azul) contra o melhor modelo, o Dropout (vermelho), em relação à linha $y=x$ (previsão perfeita). O baseline espalha suas previsões de forma mais dispersa e pouco correlacionada com o valor real, enquanto o Dropout concentra boa parte das previsões numa faixa estreita (entre ~ 0.4 e 0.55), evidenciando uma limitação real: mesmo sendo a melhor configuração, ele erra sistematicamente para valores reais mais extremos (abaixo de -0.5 ou acima de 1), “empurrando” a previsão para perto dessa faixa central. O gráfico de resíduos (Fig. 8) confirma esse padrão, com um agrupamento vertical grande de pontos perto de 0.4 e de 0.55 : mesmo o melhor modelo ainda não capturou toda a relação real entre x e y , coerente com o cenário de poucos dados de treino (30 pontos).

Limitações e reprodutibilidade: todos os experimentos usam $\text{seed}=42$ fixa; os resultados podem variar entre plataformas dado o tamanho reduzido dos conjuntos (30 pontos de treino e validação). O critério de parada foi um número fixo de épocas (3000), sem early stopping. A escolha dos hiperparâmetros de cada ablação (Tabela 1c) foi feita exclusivamente por MSE de validação, nunca pelo resultado no teste, preservando o teste como medida honesta e única de generalização, avaliada apenas ao final, depois de todas as decisões de modelo já tomadas.

Conclusão

O baseline vanilla ($R^2=-0.014$) tem desempenho pior que simplesmente prever a média de y , evidenciando a alta variância esperada com só 30 exemplos de treino para 4353 parâmetros. Entre as quatro técnicas testadas isoladamente, o Dropout foi a mais eficaz ($R^2=0.186$), seguido do Momentum ($R^2=0.131$); L2 trouxe melhora discreta ($R^2=0.003$) e L1 piorou levemente ($R^2=-0.035$), ambos com penalidades pequenas demais para mudar o comportamento da rede. Combinar as duas melhores técnicas não superou o Dropout isolado, reforçando a importância de testar cada técnica separadamente antes de assumir que combiná-las é sempre melhor.