

Projeto 1: Regressão com MLP e Estudo de Ablação

Introdução às Redes Neurais Artificiais | Aline Breda Kuster 168495
Repositório / Código Reprodutível: github.com/aline-kuster/Redes-Neurais---P1

1. Configuração Experimental e Reprodutibilidade

1.1. Pré-processamento e Partição dos Dados

O dataset (300 pontos) foi dividido em treino (10%, 30 pontos), validação (10%, 30 pontos) e teste (80%, 240 pontos), com seed=42. A proporção reduzida de treino é intencional, para forçar overfitting. O atributo x foi padronizado (z-score) usando média/desvio calculados só no treino, aplicando o mesmo transform em validação e teste (sem data leakage).

1.2. Definição e Otimização Empírica do Baseline (Vanilla)

O baseline é uma MLP treinada só com SGD puro (sem momentum, sem L1/L2/Dropout). A configuração final foi definida por busca empírica: 6 arquiteturas $\times$ 3 taxas de aprendizado (18 combinações, 3000 épocas cada), escolhida pelo menor MSE de validação atingido durante o treino. Ativação (ReLU) e tamanho de lote (8) ficaram fixos; não foi usado early stopping. A Tabela 1 mostra a configuração final.

Hiperparâmetro	Valores Explorados	Configuração Escolhida
Topologia	(8,) (16,) (32,) (16,16) (32,16) (64,64)	Entrada→Densa(64)→Densa(64)→Saída(1)
Ativação	ReLU (fixa)	ReLU
Otimizador / η	SGD puro; $\eta \in \{0.1, 0.05, 0.01\}$	SGD ($\eta = 0.1$)
Lote / Custo	batch=8 (fixo); MSE	batch=8; MSELoss
Parada / Seed	nº fixo de épocas (sem early stop)	3000 épocas; seed=42

Tabela 1: Espaço de busca e configuração final do baseline.

O log completo da busca (erro de treino e validação das 18 combinações) está na Tabela 1b; a linha destacada é a configuração vencedora: hidden=(64,64), $\eta=0.1$ (MSE treino final 0.079; menor MSE de validação: 0.312), usada como base fixa de todas as comparações a seguir.

Arq.	η	Pesos	MSE tr.	MSE val.	MSE val. mín.
(8,)	0.1	25	0.358	0.794	0.628
(8,)	0.05	25	0.272	0.712	0.600
(8,)	0.01	25	0.241	0.638	0.625
(16,)	0.1	49	0.273	0.674	0.613
(16,)	0.05	49	0.266	0.635	0.594
(16,)	0.01	49	0.228	0.619	0.615
(32,)	0.1	97	0.260	0.783	0.582
(32,)	0.05	97	0.233	0.706	0.568
(32,)	0.01	97	0.241	0.602	0.589
(16,16)	0.1	321	0.128	0.465	0.417
(16,16)	0.05	321	0.137	0.530	0.465
(16,16)	0.01	321	0.216	0.580	0.572
(32,16)	0.1	609	0.161	0.523	0.452
(32,16)	0.05	609	0.139	0.534	0.478
(32,16)	0.01	609	0.209	0.636	0.582
(64,64)	0.1	4353	0.079	0.476	0.312
(64,64)	0.05	4353	0.073	0.462	0.327
(64,64)	0.01	4353	0.188	0.649	0.556

Tabela 1b: erro de treino e validação das 18 configurações avaliadas como baseline.

2. Dinâmica de Treinamento e Convergência




Fig. 1: Baseline (treino x validação)

Sem momentum, o SGD puro é instável: a validação do baseline (Fig. 1) tem picos de $MSE \approx 0.9$ mesmo após 2000 épocas, reflexo do gradiente ruidoso de mini-lotes pequenos (batch=8) sem suavização. O overfitting já aparece nas primeiras centenas de épocas: o treino cai a ≈ 0.08 enquanto a validação estabiliza entre 0.33 e 0.55, com só 30 exemplos para 4353 parâmetros. O momentum reduz um pouco o MSE final de validação (Fig. 2), mas aumenta a instabilidade (picos > 1.2): o ganho parece vir de uma trajetória de otimização diferente, não de uma convergência mais suave.




Fig. 2: Validação — todas as configurações

3. Estudo de Ablação e Desempenho no Teste

Mantendo arquitetura, seed e η do baseline fixos, cada variação altera um único hiperparâmetro: Dropout ($p=0.3$), L2 ($\lambda=1e-5$), L1 ($\lambda=1e-6$), Momentum ($\beta=0.7$), e um Modelo Combinado (Dropout+Momentum isoladamente melhoraram o R^2). Avaliação final sobre o conjunto de teste (240 pontos, nunca usado no treino/ajuste). Resultados na Tabela 2.

Modelo / Variação	MSE	RMSE	MAE	R^2
Baseline Vanilla	0.5229	0.7231	0.5644	-0.014
+ Dropout ($p=0.3$)	0.4796	0.6926	0.5511	0.070
+ L2 ($\lambda=1e-5$)	0.5345	0.7311	0.5746	-0.037
+ L1 ($\lambda=1e-6$)	0.5268	0.7258	0.5669	-0.022
+ Momentum ($\beta=0.7$)	0.4479	0.6693	0.5356	0.131
Combinado (Dropout+Momentum)	0.4918	0.7013	0.5588	0.046

Tabela 2: Resultados no teste. Treino de 3000 épocas fixas (sem early stopping) para todas as configurações.




Fig. 3: Dropout




Fig. 4: L2




Fig. 5: L1




Fig. 6: Momentum




Fig. 7: Combinado

Fig. 3–7: Baseline (tracejado) x cada variação (sólido) — treino e validação.

Esparsidade: o baseline tinha 28/4353 pesos praticamente nulos; com L1, esse número subiu para 48/4353, tal era efeito esperado de indução de esparsidade do L1, mesmo sem melhorar o erro de teste nesta configuração de λ .

4. Discussão

O baseline vanilla teve $R^2=-0.014$ (pior que prever a média de y), evidenciando a alta variância esperada com apenas 30 exemplos de treino para 4353 parâmetros. Entre L1, L2 e Dropout testados isoladamente, só o Dropout ajudou ($R^2=0.070$); L1 (que induz esparsidade, zerando pesos) e L2 (que apenas atenua a magnitude de todos os pesos grandes, sem zerá-los) pioraram levemente o resultado. Os dois mecanismos agem de formas diferentes sobre os pesos, mas nenhum melhorou o erro de teste nesta configuração de λ . O Momentum foi isoladamente o mais eficaz ($R^2=0.131$), mas por afetar a dinâmica de otimização (Fig. 2), não por reduzir variância diretamente. Combinar Dropout+Momentum não somou os benefícios ($R^2=0.046$): o ruído do Dropout parece interferir com a suavização do Momentum, os dois mecanismos não são aditivos, um achado relevante do estudo.




Fig. 9: Resíduos do melhor modelo

Fig. 8: Real x Previsto (teste)

O parity plot (Fig. 8) mostra que boa parte das previsões de teste se concentra perto de um valor quase constante ($\approx 0.55-0.6$), pouco discriminando entre entradas diferentes, essa perda de acurácia é mais acentuada justamente nas caudas da distribuição de y (valores reais próximos dos extremos, abaixo de -1 ou acima de 2), onde o modelo mais subestima o valor real. Esse padrão de erro persiste mesmo no modelo já regularizado (momentum), sinal de que, mesmo no melhor resultado, o modelo ainda não capturou bem a função real, coerente com o cenário de poucos dados. Os resultados dependem da semente e podem variar entre plataformas dado o tamanho reduzido dos conjuntos (30 pontos); o critério de parada foi um número fixo de épocas, sem early stopping.